

Rejtett Markov Modell

A Rejtett Markov Modell használat beszédfelismerésben

Készítette Feldhoffer Gergely
felhasználva Fodróczy Zoltán előadásanyagát



Áttekintés

- „hagyományos” Markov Modell
- Beszédfelismerésbeli szerep
- Rejtett Markov Modell
- Módszerek
- Értékelés

Miről is van szó

- Beszédfelismerő módszerek
 - Izolált, kötött szótáras
 - DTW
 - ...
 - Folyamatos
 - Neuronhálós megoldások
 - HMM megoldások
 - ...
- Statisztikai alapok

Példa folyamatos feldolgozásra




Jellegvektor (Feature vector): olyan jellemzők, amik minden keretre kiszámítva alkalmasak felismerésre, szegmentálásra. A fenti képen a kockák méretét egy jellegvektor adja meg.

Folyamatos feldolgozás


- Célok:
 - szegmentálás
 - fonéma azonosítás
 - szóhatár döntések
- Bemenet: jellegvektorok
- Nehézségek:
 - bizonytalan, zajjal terhelt bemenet
 - sok hasonló fonéma, hasonulások, kiejtésbeli változatosság
 - szóhatáron nincs szünet, ismerni kell a nyelvet

Folyamatos feldolgozás




- Jellegvektorok
- Szegmentálás
- Fonéma kiválasztása
- Szóhatárok

Folyamatos feldolgozás



- Jellegvektorok
- Szegmentálás
- Fonéma kiválasztása
- Szóhatárok


Folyamatos feldolgozás



- Jellegvektorok
- **Szegmentálás**
- Fonéma kiválasztása
- Szóhatárok

Szemre
is látható


Folyamatos feldolgozás



- Jellegvektorok
- Szegmentálás
- **Fonéma kiválasztása**
- Szóhatárok


Szemre
kevésbé
látható

Folyamatos feldolgozás



- Jellegvektorok
- Szegmentálás
- Fonéma kiválasztása
 - Fonéma jelöltek pontozása:
 - jellegvektorok
 - statisztika
 - Statisztika és szótár alapján választás
- Szóhatárok

Folyamatos feldolgozás




- Jellegvektorok
- Szegmentálás
- Fonéma kiválasztása
 - Fonéma jelöltek pontozása:
 - jellegvektorok
 - statisztika
 - Statisztika és szótár alapján választás
- Szóhatárok

Neuronháló

HMM

Markov Modell

- Állapotok, állapotátmenetek



Markov Modell példa: időjárás

- Állapotok: $S=\{S1:Napos, S2:Borult, S3:Esős\}$
- Állapotátmenetek:
$$A=\{a_{i,j}\} = \begin{vmatrix} 0,4 & 0,3 & 0,3 \\ 0,2 & 0,6 & 0,2 \\ 0,1 & 0,1 & 0,8 \end{vmatrix}$$
-
-
- Kérdés: adott állapot-sorozat valószínűsége
- Pl: Mi az esélye, hogy egy Napos állapot után $\{Napos, Esős\}$ sorozat következzen?

Markov Modell példa: időjárás

- Állapotok: $S=\{S1:Napos, S2:Borult, S3:Esős\}$
- Állapotátmenetek:
$$A=\{a_{i,j}\} = \begin{vmatrix} 0,4 & 0,3 & 0,3 \\ 0,2 & 0,6 & 0,2 \\ 0,1 & 0,1 & 0,8 \end{vmatrix}$$
-
-
- Kérdés: adott állapot-sorozat valószínűsége
- Pl: Mi az esélye, hogy egy Napos állapot után $\{Napos, Esős\}$ sorozat következzen?
- $P(\{S1,S1,S3\}|S1)=1*a_{1,1}*a_{1,3}=1*0.8*0.3=0.24$

Markov Modell

Beszéd felismerésben

- Az állapotokat a fonémáknak feleltetjük meg
- Az állapotátmenetek ismertek:
- Nagy adatbázisokból kinyerhető az A mátrix
- Állapotok?

Markov Modell

Beszéd felismerésben


- Az állapotokat a fonémáknak feleltetjük meg
- Az állapotátmenetek ismertek:
- Nagy adatbázisokból kinyerhető az A mátrix
- Állapotok?
- Sajnos éppen az állapotok bizonytalanok
- Megfigyelésekre hagyatkozhatunk csak
- Viszont vannak megfigyelt sorozataink!

A Rejtett Markov Modell (HMM)

- Minden állapothoz hozzárendelhető a lehetséges megfigyelések valószínűsége
- $e_{si}(x)$: x megfigyelés valószínűsége az i állapotban
- Ismerjük az állapotátmeneti valószínűségeket: Az A mátrix
- Keressük az állapotok sorozatát megfigyelések sorozata alapján


A Rejtett Markov Modell (HMM) Példa

- Egy oktató többféle állapotban lehet:
S1:jókedvű, S2:közömbös, S3:ideges
- A házifeladat feladásában befolyásolja ez az állapot, de nem határozza meg teljesen
- A házifeladat lehet O1:könnyű, O2:félórás, O3:többórás
- $e_{s_1} = \{0.7, 0.2, 0.1\}$
- $e_{s_2} = \{0.3, 0.4, 0.3\}$
- $e_{s_3} = \{0.0, 0.1, 0.9\}$
- Tudjuk:milyen házifeladatot adott egy hétig



A Rejtett Markov Modell (HMM) Példa

- Megfigyelések: {O1, O3, O1, O2, O3}
- Keressük a legvalószínűbb állapot-sorozatot
- Megoldás: Viterbi algoritmus
 - halmozott valószínűségek
 - utolsó állapot
 - visszakövetkeztetés



A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0,7/3				
Közömbös	0,3/3				
Ideges	0,0/3				

Az első oszlopba kerülnek azok a valószínűségek, amik kezdetben érvényesek. Feltételezve egyenletes eloszlást, a megfigyelések valószínűségeit elosztjuk az állapotok számával (a későbbiekben ennél okosabban is lehet csinálni, például külön kezelni a kezdőállapotok valószínűségeit)

A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	?			
Közömbös	0.100				
Ideges	0.000				

A következő oszlopba már az állapotátmenet valószínűségeket is bele kell számolni.

$$V_{2,l} = e_l(O3) * \max_k \{ V_{1,k} * a_{k,l} \}$$

$$V_{2,S1} = e_{S1}(O3) * \max \{ V_{1,1} * a_{1,1}, V_{1,2} * a_{2,1}, V_{1,3} * a_{3,1} \}$$

$$V_{2,S1} = 0,1 * \max \{ 0.233 * 0.2 = \mathbf{0.0466},$$


$$, 0.1 * 0.3 = \mathbf{0.03}, 0.0 * 0.5 = \mathbf{0} \}$$

$$V_{2,S1} = 0.00466$$

$$e_{S1} = \{0.7, 0.2, 0.1\}$$


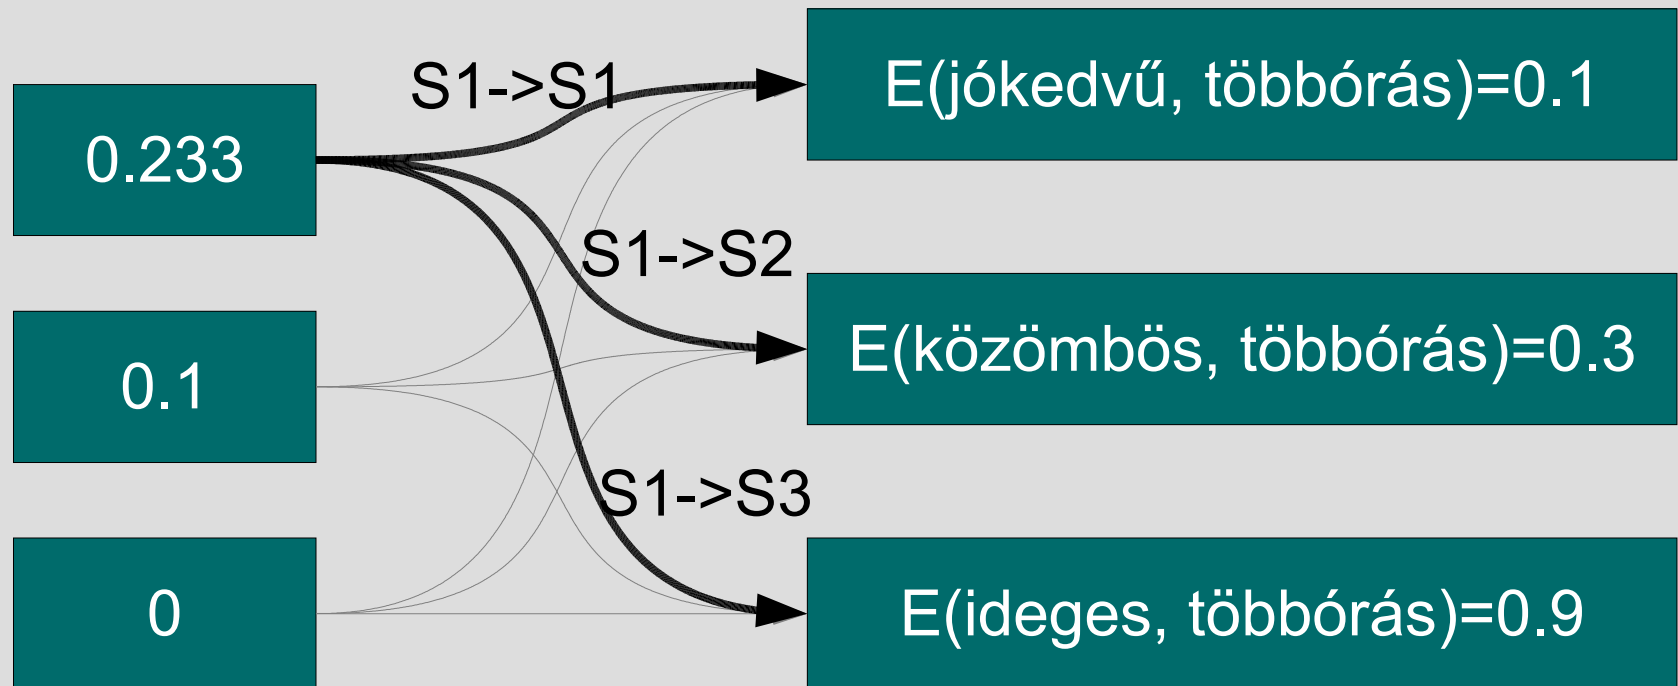
$$e_{S2} = \{0.3, 0.4, 0.3\}$$

$$e_{S3} = \{0.0, 0.1, 0.9\}$$



A Rejtett Markov Modell (HMM)

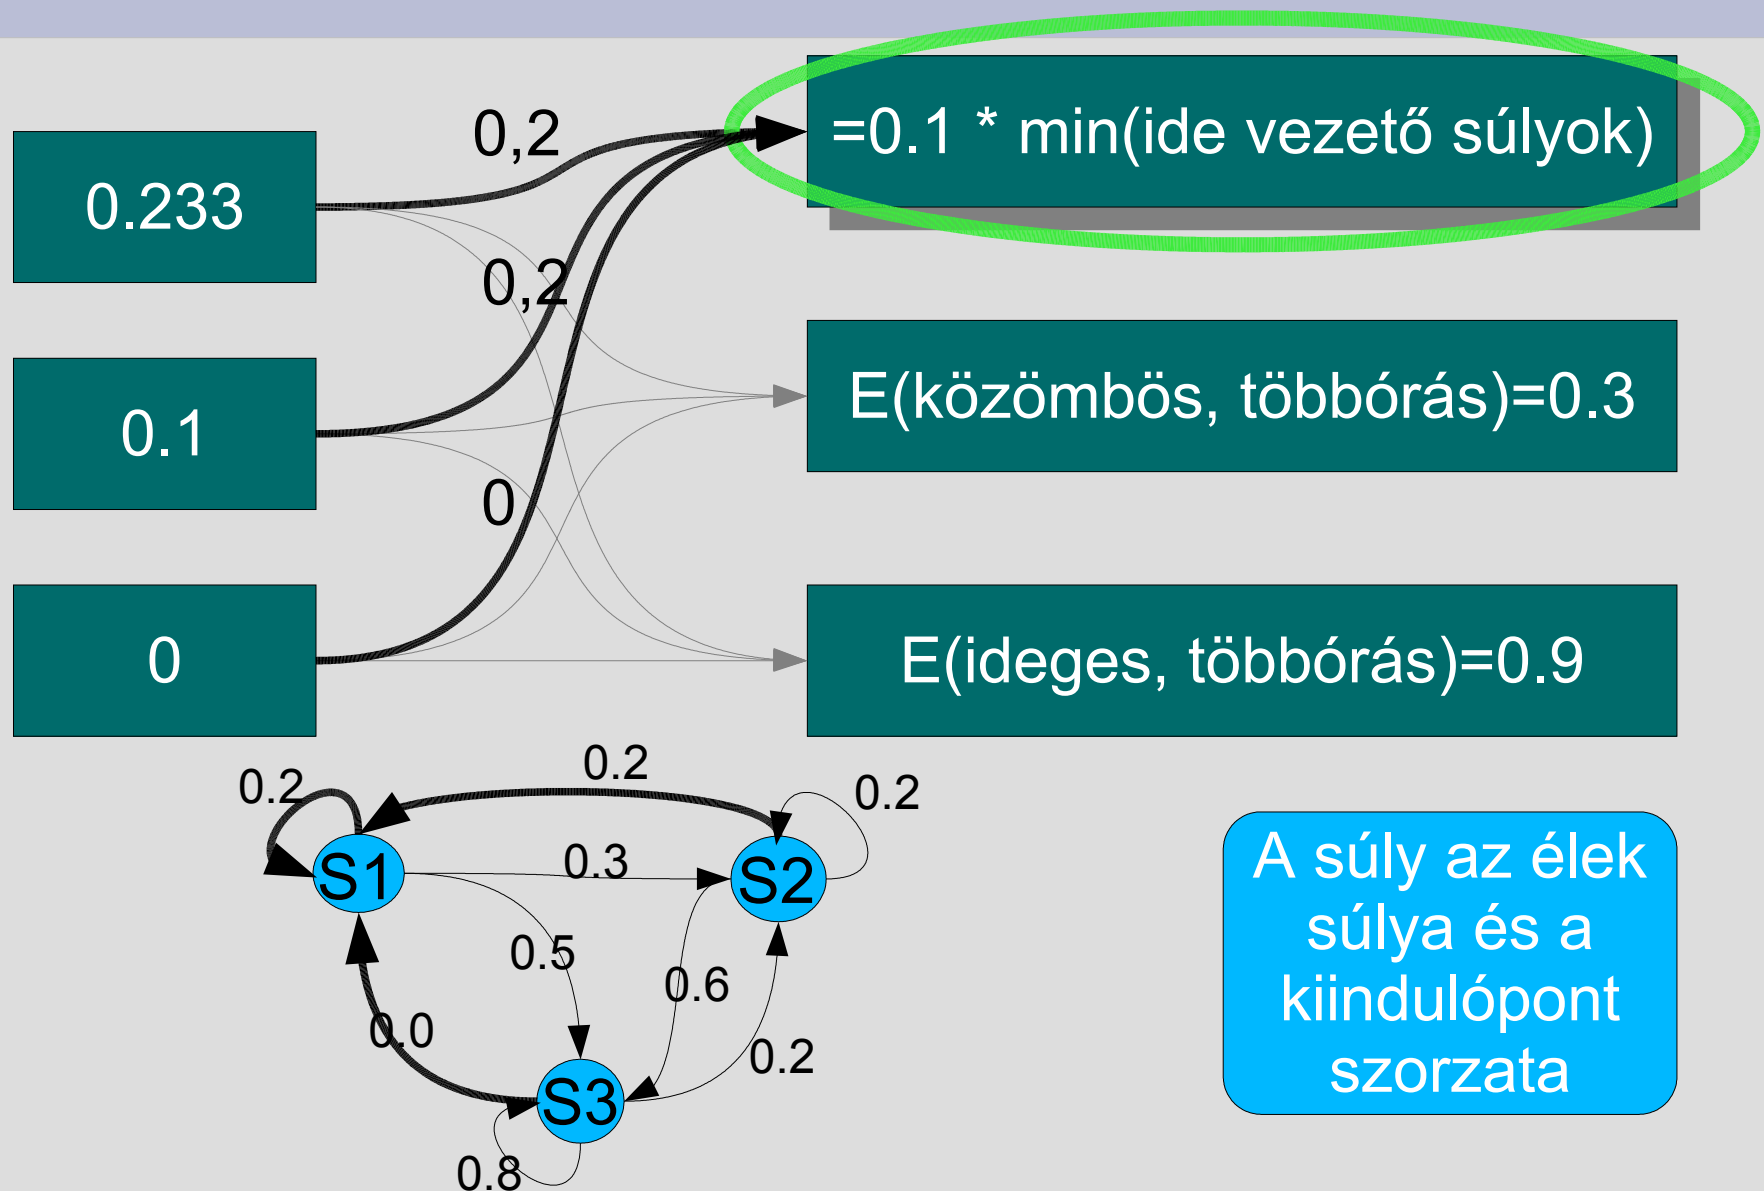
Példa: Viterbi



A második megfigyelés a "többórás"

A Rejtett Markov Modell (HMM)

Példa: Viterbi



A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233 ←	0.00466			
Közömbös	0.100				
Ideges	0.000				

A következő oszlopba már az állapotátmenet valószínűségeket is bele kell számolni.

$$V_{2,l} = e_l(O3) * \max_k \{ V_{1,k} * a_{k,l} \}$$

$$V_{2,S1} = e_{S1}(O3) * \max \{ V_{1,1} * a_{1,1}, V_{1,2} * a_{2,1}, V_{1,3} * a_{3,1} \}$$

$$V_{2,S1} = 0,1 * \max \{ \mathbf{0.233 * 0.2 = 0.0466},$$


$$, 0.1 * 0.3 = 0.03, 0.0 * 0.5 = 0 \}$$

$$V_{2,S1} = 0.00466$$

$$e_{S1} = \{0.7, 0.2, 0.1\}$$

$$e_{S2} = \{0.3, 0.4, 0.3\}$$

$$e_{S3} = \{0.0, 0.1, 0.9\}$$




A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.00466			
Közömbös	0.100	0.0207			
Ideges	0.000	0.105			

Minden értékhez megjegyezzük, hogy a maximális valószínűség melyik állapot felől következett




A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.00466	0.00294	0.000252	0.0000108
Közömbös	0.100	0.0207	0.0063	0.000504	0.0000324
Ideges	0.000	0.105	0.000	0.000378	0.0002721

Végigszámoljuk az egész táblát




A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.00466	0.00294	0.000252	0.0000108
Közömbös	0.100	0.0207	0.0063	0.000504	0.0000324
Ideges	0.000	0.105	0.000	0.000378	0.0002721

Kiválasztjuk a maximumot az utolsó állapotban.

A halmozott valószínűségek közül a maximálisat választva egy egész sorozatot választunk




A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.00466	0.00294	0.000252	0.0000108
Közömbös	0.100	0.0207	0.0063	0.000504	0.0000324
Ideges	0.000	0.105	0.000	0.000378	0.0002721

Így a maximális választások útján visszafelé haladva a teljes állapot-sorozat visszakövetkeztethető.

Az eredmény: {S1,S3,S2,S3,S3}



A Rejtett Markov Modell (HMM)

Példa: Viterbi

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.00466	0.00294	0.000252	0.0000108
Közömbös	0.100	0.0207	0.0063	0.000504	0.0000324
Ideges	0.000	0.105	0.000	0.000378	0.0002721

Megjegyzés:

Látható, hogy vannak olyan értékek, amik helyben maximálisak, mégsem képezik részét a végeredményben kapott útnak. A naiv, egyértelműen hozzárendelő elv szerint is, a jelzett valószínűség szerint is az S2 lett volna a nyerő, de a teljes folyamatban ez már nem igaz.

Viterbi algoritmus C++ nyelven

```
for (int i=1;i<o.size();i++) {  
    for (int j=0;j<a.size();j++) {  
        maxv=0;  
        for (int k=0;k<3;k++)  
        {  
            tmp=v[k][i-1]*a[k][j];  
            if (maxv<tmp) {maxv=tmp; max=k;}  
        }  
        v[j][i]=maxv*e[j][o[i]];  
    }  
}
```

Ahol a az A mátrix, o a megfigyelések sorozata, e az állapothoz tartozó megfigyelés-valószínűségek mátrixa, v a Viterbi táblázat.

Összefoglalás

- A HMM jól leírja a beszédfolyamatokat
- Megfigyelés bármilyen jellegvektor lehet
- Állapotoknak a fonémákat nevezzük ki
 - Az optimális állapotsorozat feladatára a Viterbi algoritmus a megoldás
- A módszer a dinamikus idővetemítéshez hasonlóan egy valószínűségthalmozás, és egy visszafelé haladó optimális út keresés
- Dinamikus programozás
- Kitekintés: Viterbi eredetileg jelátvitel hibajavítására találta ki az algoritmust

Más HMM algoritmusok

- Az előre felé következtetés
- A kérdés: egy bizonyos megfigyeléssorozatnak mi a valószínűsége
- A megoldás: HMM-Forward algoritmus
- Az előző táblázathoz hasonló, de maximum kiválasztás helyett összegzés: minden lehetőséget összegzünk, nem legjobbat keressünk
- $f_{s,i} = e_s(O) \sum_k (f_{k,i-1} * a_{k,s})$

Forward algoritmus

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	?			
Közömbös	0.100				
Ideges	0.000				

Az első oszlop ugyanúgy megy, mint a Viterbinél, majd

$$f_{s,i} = e_s(O) \sum_k (f_{k,i-1} * a_{k,s})$$

A következő oszlop mindegyikére ki kell számolni a lehetséges útvonalakhoz tartozó valószínűségek összegét:

$$(0.233 * 0.2 + 0.1 * 0.2 + 0.00 * 0.5) = 0,066$$

Majd ezt megszorozni a megfigyelés valószínűségével:

$$0,1 * 0,066 = 0,0066$$

Forward algoritmus

	Könnyű	Többórás	Könnyű	Félórás	Többórás
Jókedvű	0.233	0.0066	0.004713	0.000658	0.000043
Közömbös	0.100	0.027	0.01176	0.001506	0.000206
Ideges	0.000	0.159	0.000	0.000941	0.001787

Kiszámítjuk az összegeket.

A végeredmény az utolsó oszlop összege: 0,002036

Ez tehát az a valószínűség, ami egyenletes eloszlás szerinti kezdőállapot mellett a fenti megfigyelés-sorozathoz tartozik

Forward algoritmus C++ nyelven

```
for (int i=1;i<o.size();i++) {  
    for (int j=0;j<a.size();j++) {  
        sum=0;  
        for (int k=0;k<3;k++)  
            sum +=f[k][i-1]*a[k][j];  
        f[j][i]=sum*e[j][o[i]];  
    }  
}
```

Ahol az a a rákövetkezési mátrix, az e a megfigyelések valószínűsége, o a megfigyelések sorozata, f a Forward mátrixa.

Paraméterek becslése

- Ahhoz, hogy egy HMM sikeresen működjön beszédfelismerési, vagy egyéb rendszerekben, az A és E mátrixok pontos becslése szükséges.
- Ezeket az értékeket adatbázisok tartalmából ki lehet számítani megközelítőleg
- A megoldás a statisztika, azon belül is a maximum likelihood módszer.

Paraméterek naív becslése

- Az A mátrix elemeinek becslése:
- Legyen $T_{i,j}$ az adatbázisban található $i \rightarrow j$ átmenetek száma.
- $a_{i,j} = T_{i,j} / (\sum_k T_{i,k})$
- Így igaz lesz, hogy $\sum_k a_{i,k} = 1$ minden i -re

Paraméterek naív becslése

- Az E mátrix elemeinek becslése:
- Legyen $O_{i,j}$ az adatbázisban található j megfigyelések száma, amik i állapotban fordultak elő.
- $e_{i,j} = O_{i,j} / (\sum_k O_{i,k})$
- Így igaz lesz, hogy $\sum_k e_{i,k} = 1$ minden i -re

Paraméterek becslése

- A naív becslés sajnos nem optimális
- Az optimális paraméterek megadására analitikus megoldás nem ismert
- Közelítő módszerrel pontosabb:
- Baum-Welch algoritmus

Baum – Welch algoritmus

- Jelölje V a Viterbi algoritmus táblázatát, és F a Forward algoritmusét.
- $V(i,j)$ illetve $F(i,j)$ az i -edik megfigyelés j állapothoz tartozó valószínűsége
- Jelentse $\text{Mod}=(A,E)$ egy modell minden paraméterét, ezt szeretnénk optimalizálni
- Végül jelentse O a megfigyelések sorozatát
- A BW algoritmus már 3 dimenziós táblával dolgozik
- Jelentse $\text{BW}(t,i,j) = P(S_t=S_i \ \& \ S_{t+1}=S_j \mid O, \text{Mod})$

Baum – Welch algoritmus

- $BW(t,i,j) = P(S_t=S_i \ \& \ S_{t+1}=S_j \mid O, \text{Mod})$
- $BW(t,i,j) =$
 $P(S_t=S_i \ \& \ S_{t+1}=S_j \ \& \ O \mid \text{Mod}) / P(O \mid \text{Mod})$
- A levezetést nem fejtjük ki, ami fontos:
- Ez a valószínűség kifejezhető a Viterbi és a Forward algoritmusok táblázataival
- Ennek alapján egy iteratív módszerrel egyre jobb Mod modell adható

Baum – Welch algoritmus

$$\overline{A(i,j)} = \frac{\text{Si} \rightarrow \text{Sj állapotátmenetek várható értéke}}{\text{Si-ből induló állapotátmenetek várható értéke}}$$

$$\overline{E(i,j)} = \frac{\text{Si állapotban Oj-t megfigyelések várható értéke}}{\text{Si állapot előfordulásának várható értéke}}$$

- Vegyük észre: Ha az A és E mátrixok változnak, más lesz a várható érték – ettől lesz az algoritmus iteratív
- Fixpont tétel: Ez egy kontrakció, tehát ha egy Mod paraméterállapota a fenti iteráció egy lépése ugyanezt a Mod paraméterállapotot adja, akkor az a keresett szélsőérték.

Baum – Welch algoritmus

Összefoglalás

- A naív becslés egy torzítatlan egylépéses iteráció a BW algoritmushoz képest
- A tanítás iteratív volta miatt a neuronhálózatos módszerekhez hasonlóan a tanítás sebessége a tanító adatbázis méretétől és jellegétől függ
- Statisztikai szemszög: Gauss eloszlások keverékét szeretnénk szeparált (ismert) Gauss eloszlások összegeként előállítani

HMM: Értékelés

- Az állapot-sorozatok elemzésével a fonémák kinyerhetőek a beszédjelből
- Ez jóval erősebb eszköz a dinamikus idővetemítésnél, ami csak egész kifejezések felismerésére használható
- Tanítható
- Részben beszélőfüggetlen, a beszélőn főleg az E mátrix múlik
- A megfigyelések halmaza tetszőlegesen választható (pl spektrális információ és energia, egyéb akusztikus jegyek)

Problémák

- Szegmentálás: ekvidisztáns időkeretek, vagy szegmentálási algoritmus?
- Egyforma keretek esetében sok múlik a keretek méretén. Ha a keret túl kicsi, az $a_{i,i}$ értékek túl nagyok lesznek.
- Szegmentálási algoritmus esetében az éles használatkor az adatbázistól eltérő körülmények között (más zaj, stb) elromolhat az A mátrix.

Lehetőségek

- Hierarchikus HMM: fonémák szintje, szavak szintje, nyelvtani szint
- Adaptív HMM: a modell folyamatosan változik használat közben, fenntartva a modell lehetőségekhez mért optimalitását
- Másodrendű, sokadrendű HMM: az állapotátmenetek nem csak a megelőző, de a megelőző n mintától függnnek.

HTK (HMM Tool Kit)

- A HTK egy C/C++ könyvtár, ami hangfeldolgozó eljárásokat, és sok beszédfelismerésben hasznos algoritmust tartalmaz
- Többek között:
 - HMM
 - LPC, és egyéb előfeldolgozók
 - Nyelvi modell
 - Fájlformátumok
 - VQ

HTK (HMM Tool Kit)

- Fájlformátumok:
 - Saját formátumok
 - Hangfájlok (WAV, AIFF, AU8 ..)
 - Tesztanyagok címkézései (TIMIT, SCRIBE ..)
- HMM
 - Adatszerkezetek modellekhez, akár többrendűekhez
 - Többféle tanítási módszer
 - Viterbi/Forward és egyéb kiértékelések
 - Adaptív HMM

Egy HMM rendszer felépítése

1. fázis

Adatbázis

Tanítás
(BW)

Modell

2. fázis

Modell

Input

előfeldol-
gozás

Jellegvektorok

Viterbi

Fonéma
sorozat

